四六级词汇量检测 · 技术文档

项目名称：四六级词汇量检测（CET Vocabulary Profiler） | 版本：v1.0 | 文档日期：2026-10-29

参赛赛事：筑视界·码绘交互 —— Web 前端开发创意技能大赛 | 选题方向：AI 教育与学习平台

作者：李壹铭 | 广东亚视演艺职业学院 · 人工智能学院 | 单人作品

代码仓库：https://github.com/whiteyuexi/cet4-vocab-check

7,175	9,204	433	2.11 MB
词条（全部带音标）	英中对照例句	条离线断言	单文件产物

0
运行时外部依赖

1 项目概述
2 需求分析
3 系统架构设计
4 AI 技术方案
5 核心功能实现
6 测试与部署
7 创新点说明
8 总结与展望
附录 A–D

1 项目概述

1.1 一句话定位

这是一个**词汇量测量工具**，不是背单词软件。用户花 3 分钟测出自己有多少词量、误差多大、薄弱在哪个词频段， 再决定背什么。背单词这件事仍然交给用户习惯的工具——本产品只负责"测准"和"开出补词清单"。

1.2 交付物与完成度

交付物	内容	状态
Web 单文件产物	`index.html` 2.11 MB，词库/例句/立绘/样式/脚本全部内联，双击即用、断网可用	完成
评委版产物	同一份产物 + 内联作者 Key，开箱即可演示在线 AI 诊断（仓库版不含任何密钥）	完成
微信小程序	同源引擎的移动端版本，5 个页面，主包 1.56 MB，可直接导入开发者工具	完成
文档	本技术文档（PDF）、产品介绍（HTML）、功能总览、报告系列 01–18、README / NEXT / LICENSING	完成
演示材料	路演稿、详细资料稿（含附录）、演示视频分镜脚本	完成
自动化测试	12 个套件 / 433 条离线断言（另 7 条联网断言），全绿	完成

1.3 三个亮点

亮点	具体是什么	怎么验证
① 敢写误差	结果永远是"数字 + 95% 区间 + 严格/折中两套口径"，题量由用户设定的目标精度决定，而不是固定 20 题	首页大数字下方即区间；改目标精度看题量与区间宽度同时变化
② 结论可执行	输出到"先补哪一段、哪些词、每天几个、几天补完"，并按「缺口 × 词频权重」排序	报告页补词清单；每条可直接开始复测
③ 离线可用且 AI 不编数字	单文件零依赖、断网可用；有 AI 时 AI 只解释数据，所有数字来自工具返回值	屏蔽网络后跑 20 项断言；AI 面板看工具调用标签与依据面板

1.4 技术栈

前端	原生 HTML / CSS / JavaScript（ES5 语法，无框架、无构建期依赖注入），单文件交付
后端（可选）	Node.js 原生 `http` + SSE，无 Web 框架、无第三方运行时依赖
数据	词库 JSON（7,175 词）、Tatoeba 英中语料（9,204 句），构建期裁剪后内联
AI	OpenAI 兼容协议（DeepSeek / 通义千问 / 智谱 GLM） + 本地 Ollama + 确定性规则引擎兜底
构建/测试	Node 18+；jsdom 做页面级测试，Chrome DevTools Protocol 做真实浏览器断言，python-pptx 做 PPT 结构交叉校验

2 需求分析

2.1 用户画像与场景

用户	场景与核心诉求
备考四六级的学生	想快速知道"我现在什么水平、差在哪、先补什么"，不愿意先做 1000 道题
需要验证复习效果的人	背了两周，想知道涨的这点分是真进步还是抽样噪声
英语教师 / 班干部	给学生做词汇摸底，需要能导出、不联网、数据不外泄
共用电脑的用户	实验室或宿舍同一台机器多人使用，数据必须互相隔离

2.2 功能需求

编号	需求	状态
F1	四/六级双词库检测（4,540 / 5,716 词），共用一份作答记录	完成
F2	五种检测入口：快速摸底、高精度、完整检测、分组检测、薄弱词复测	完成
F3	结果给出词汇量 + 95% 区间 + 两套口径 + 区间随题量收窄	完成
F4	七段词频剖面与「缺口 × 词频权重」优先级排序	完成
F5	等级评估（S/A/B+/B/C/D） + 高频段地基封顶	完成
F6	多轮检测与逐词差分（真学会 / 背了又忘 / 掉档）	完成
F7	词汇地图：七段 × 26 字母 = 182 格，点格子直接复测	完成
F8	AI 诊断：三档通路、工具调用、建议可点、图表可反向提问	完成
F9	自定义词书导入（txt / csv / 粘贴），并明确"不换算成词汇量"的边界	完成
F10	使用者档案：同机多人数据隔离，可切换/改名/删除	完成
F11	导出：未掌握词表 CSV、作答备份 JSON、报告文本、打印 PDF	完成
F12	回访卡：隔几天再打开，用上次结果给出三段结论	完成
F13	每日可投入时间：分钟 → 每天词数 → 四处文案统一	完成
F14	一键生成六个等级的示例账号（演示用）	完成
F15	语音朗读单词（依赖系统语音引擎）	完成

2.3 非功能需求

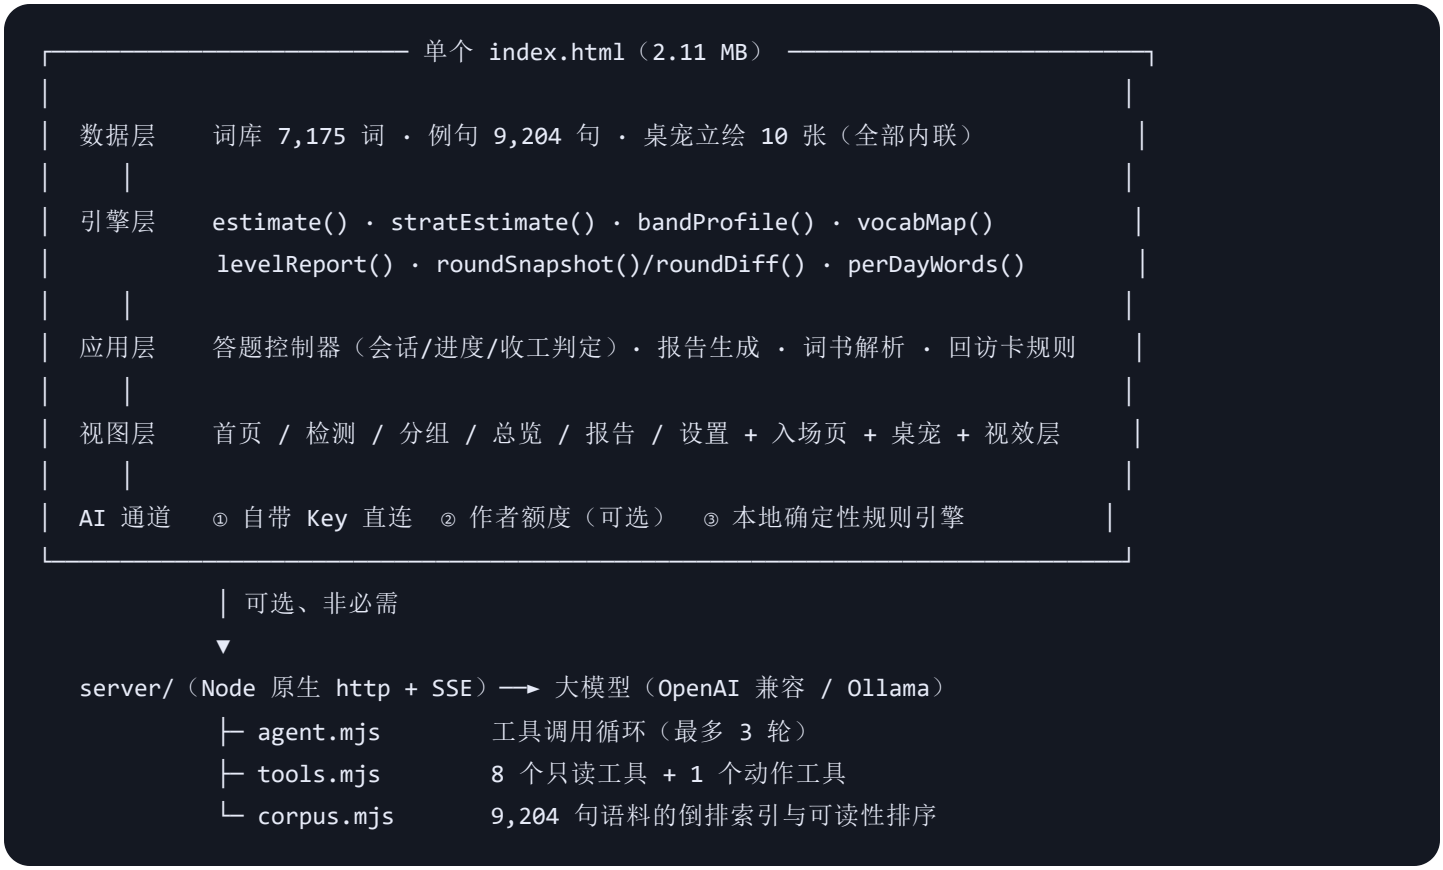
维度	要求	达成方式
离线可用	断网、无外部资源、无同目录依赖也能完整使用	单文件内联一切；断网跑 20 项断言
隐私	逐题作答不出本机，只把汇总数据交给可选的大模型	localStorage 存储；上行字段白名单
性能	首屏 < 300 ms（本机），交互不卡顿	无框架、无虚拟 DOM；动效只动 transform/opacity
可访问性	键盘可操作、对比度达标、尊重减少动效	焦点管理 + inert + 实测 4.83:1 / 5.72:1
可维护	改一处生效一处，回归可自动验证	427 条断言 + 11 个套件；产物可复现
移动端	390 px 宽可用	响应式；实测无横向溢出、顶栏单行

2.4 明确不做的边界

不做背单词	没有复习队列、没有打卡、没有提醒推送——那是另一条重资产赛道
不做账号与云同步	没有登录、没有服务器存档；换设备靠导出/导入 JSON
不做向量库 RAG	embedding + 向量库会引入几十 MB 权重，直接毁掉"单文件、断网可用"
不从自定义词书外推词汇量	自定义词书是有偏样本，只报"对这本书的掌握率"，界面上常驻提示

3 系统架构设计

3.1 整体架构



3.2 模块划分

文件	规模	职责
src/app.part1.js	1,492 行	状态与存储、词库与频段、抽样与估计、等级报告、回访卡、演示档案、使用者档案
src/app.part2.js	431 行	答题引擎：题面、作答判定、撤销、跳过、收工、结算
src/app.part3.js	922 行	结果页、总览、报告、设置、事件分发
src/app.part4.js	936 行	AI 面板、三档通路、工具调用可视化、动作白名单
src/app.part5.js	816 行	2.5D 桌宠：行为、悬空物理、守卫、气泡
src/app.part6.js	542 行	等级报告页与多轮对比
src/app.part7.js	378 行	入场页与视效层
src/app.part8.js	330 行	自定义词书解析 / 预览 / 保存
build.js	—	把 CSS/JS/词库/例句/立绘按固定顺序拼进 `index.template.html`
server/	约 400 行	可选后端：静态托管 + Agent 循环 + 工具层 + 语料检索

3.3 数据模型与存储

作答状态	按词下标存 1 个字节：0 不认识 / 1 模糊 / 2 认识 / 缺失即未测
轮次归档	聚合快照（词汇量、双口径、七段、等级） + 逐词 2 bit 位图（7,175 词约 1.8 KB），最多保留 12 轮
词表指纹	FNV-1a，形如 `7175:xxxx`；指纹不一致时只做聚合对比，不硬算逐词差异
存储键	`cet4vocab_profiles`（档案表）、`cet4vocab_v1`（首个档案，兼容旧数据）、`cet4vocab_v1::<id>`（其余档案）
容量估算	单轮约 1.8 KB 位图 + 少量聚合字段；localStorage 5 MB 可存上千轮，实际限制在 12 轮

3.4 构建与两种产物

```
node build.js              # 仓库版：不含任何密钥，可公开
node build.js --with-key   # 评委版：内联作者 Key，开箱可演示在线 AI
# 产物不写入构建时间戳，同样源码构建出同样文件（可用 SHA256 比对）
```

提交前必须有一步 `node scripts/check-no-key.mjs`：扫描产物与文档，确认没有明文 Key 泄漏。 仓库里 `private/ai-key.json` 与 `.env*` 均被 gitignore。

3.5 关键设计决策

决策	理由
单文件交付	学生真实环境是"发个文件就能用"，不装环境、不被墙、不怕链接失效；代价是词库要裁剪、体积要控在 2 MB 出头
零运行时依赖	不引框架，避免"三年后依赖装不上"；统计与渲染都是手写，代码可读、可审计
AI 可选而非必需	大模型要花钱、可能没网；把它做成"增强项"，没有它功能不残缺
数字由本机算	模型的算术不可靠；所有统计量在浏览器内算完，模型只解释与排序
同一套引擎多端复用	小程序版直接复用同一份引擎逻辑，用一致性测试保证逐字段相等，避免"两端数值不一样"

4 AI 技术方案

4.1 选型理由：AI 放在哪里、不放在哪里

AI 在这类教育工具里最容易犯两个错：一是替用户算数（算出好看但不准的数字），二是把它当必需品（没网就废）。 本项目的取舍是：**统计与判定全部由确定性代码完成，AI 只负责把已经算好的数据翻译成行动建议。**

环节	由谁负责	理由
抽样、区间估计、等级判定	确定性代码	可复现、可断言；同一份数据永远得出同一个数
题目排序、分组边界	确定性代码	FNV-1a 定序，保证不同设备抽到同一批词
"我该先补哪一段"的排序	确定性代码给出候选	缺口 × 词频权重是硬规则，模型不参与打分
解释、追问、把结论组织成计划	**大模型**	这类任务没有唯一答案，正适合语言模型
没有模型时的同等能力	本地规则引擎	保证"永远可用"，且在数据不足时敢说"下不了结论"

4.2 集成方式：三种形态与三档通路

档位	触发条件	能力
① 自带 Key	用户在设置里填了自己的 API Key	直连厂商、不限次数；Key 只存本机，导出备份时剔除
② 作者额度	完成一次有效检测换取 1 次深度诊断（仅评委版内联了作者 Key）	在线大模型；额度用尽自动降级
③ 本地方案	以上都不满足、或没有后端	确定性规则诊断，不联网、不限次、按真实数据出结论

```
A.aiTier = function () {
  if (A.S.userKey && A.S.userKey.key) return 'user';        // 用户自己付费，优先
  if (AUTHOR_KEY && A.aiQuota().left > 0) return 'author';   // 作者额度
  return 'local';                                            // 永远可用的兜底
};
```

额度是"完成检测换来的"，所以不能白给：同一轮、同口径只授予一次（用 `kind:bank:round.startedAt` 去重）， 整库检测要求测过 ≥100 词且覆盖 ≥95%，随机摸底要求 ≥80 题且达到目标精度。

4.3 Agent 与工具调用

后端是一个极简的函数调用循环：模型说"我要看频段数据"，服务端执行工具、把 JSON 结果回灌，直到模型给出回答或超过 3 轮。 关键是**模型的输出永远不直接进界面数字位**——界面上的数字来自工具返回值。

工具	作用
get_profile	取整体情况：词汇量、区间、双口径、覆盖率、四态统计
get_band_profile	取七段词频掌握率与缺口
get_weak_words	取没掌握 / 没测过的词清单
make_plan	按每日可投入时间折算补词计划
get_examples	按需检索真实例句（RAG）
get_round_diff	取多轮差分：真学会 / 背了又忘 / 掉档
get_map_cell	取词汇地图某一格的数据
get_quota	取当前 AI 档位与剩余额度
suggest_actions	动作工具：给出可点按钮（go / start / review / ask）

循环上限	`MAX_TOOL_ROUNDS = 3`，避免模型无限取数
输出预算	`maxTokens = 1000`；历史只带最近 6 条，控制成本
流式协议	SSE 事件：`mode` / `tool` / `delta` / `actions` / `done` / `error`
可视化	界面把"这次调了哪几个工具、拿到了什么"渲染成标签，回答下方可展开"本次发送给模型的数据"

4.4 提示工程：三条硬规矩

```
你是「四六级词汇量检测」工具里的诊断教练。规则：
1）所有数字必须来自工具返回值，不许自己估算或编造；
2）数据不足（样本 < 30 或覆盖率 < 95%）时直接说"样本太少，下不了结论"；
3）掌握率只有两种口径：严格（只算认识）与折中（模糊算一半），不要自创第三种。
```

这三条不是写在文档里的愿望，而是被断言守着的：`check-ai-link.mjs` 会验证"动作按钮真的执行"、 "非法动作被拒绝"、"越界参数被规整"； `check-ai-tiers.mjs` 验证额度授予/扣减/下限保护。

4.5 轻量 RAG：例句是查出来的

语料	Tatoeba 英中对照句 9,204 句（CC-BY 2.0 FR），覆盖 5,138 个词
索引	构建期建"单词 → 候选句"倒排索引，并按可读性打分：词数接近 10–12、长度 60–80 字符、主语开头加分
运行期	模型需要举例时调 `get_examples`，返回真实句子 + 中文译文 + 来源标注
为什么不用向量库	向量方案要拖入几十 MB 权重，与"单文件 + 断网可用"直接冲突；本例的检索需求是精确命中单词，倒排索引足够且可解释

4.6 双向联动与动作白名单

图 → AI	点频段条的「问」或 Shift + 点地图格子，问题文本里自动带上该块的真实数字，用户不用复述
AI → 图	回答末尾给出可点按钮；点击后真的执行（复测该段 / 开一轮摸底 / 跳转页面）
安全边界	模型输出被当作**不可信输入**：动作类型必须在白名单内，路由必须合法，target 夹到 {150,250,400}，频段夹到 0–6，问题文本截断到 120 字
按钮绑定	每个按钮携带自己的动作对象（不是全局下标），避免"点了执行的是上一组的动作"

4.7 优化策略

策略	做法与效果
降级链	Agent（带工具）→ 直连模型（无工具）→ 本地规则。任一环失败都不弹错误框，而是在回答里说明当前形态
成本控制	额度一次一授予；同一轮去重；历史截断 6 条；输出上限 1000 token；不需要 AI 的功能一律本地算
稳定性	后端探活后再决定走 Agent 还是直连；SSE 断流有终态事件；超时与异常都落到本地规则兜底
可观测	面板实时显示档位徽标（自带 Key / 作者额度剩几次 / 本地方案）与工具调用标签
密钥安全	可选授权锁：Key 用 `PBKDF2-SHA256（60 万次）+ AES-256-GCM` 加密后内联，产物里无明文；解密只存内存

4.8 实测结果

联网主路径	`check-online-ai.mjs` 7 项：回答来自模型、至少调用 1 个工具、带依据面板（实测 tool=3）
离线一致性	同一份数据下，本地方案与在线诊断的**数字部分完全一致**（都来自同一批工具/同一套代码）
拒绝下结论	样本不足时模型输出"样本太少"，`check-ai-link.mjs` 有对应断言

5 核心功能实现

5.1 检测的五个入口，共用一套统计内核

入口	题量	用途与口径
快速摸底	约 80–130 题	分层随机抽 100 词，得到带区间的词汇量估算；3–5 分钟
高精度	约 210–340 题	同一算法、目标误差 ±250 或 ±150，达标自动停
完整检测	整库 4,540 词	覆盖率 ≥95% 后转普查口径，逐词统计，不再外推；产出等级
分组检测	每组 100 词	可中断、可分工推进；只报进度，不外推词汇量
薄弱词复测	按缺口词量	把没掌握/没测过的词组成一轮，用于验证是否真的补上

5.2 词频分层抽样

词表按词频切七段（最高频 1k … 20k 以外），每段等比例抽。这样任何一个前缀都是一个合法的等比例样本， 因此可以边测边算精度、随时喊停。做法上还有两个细节：

稳定乱序	用词自身的 FNV-1a 哈希定序：视觉上完全打乱，但每次打开、每台机器完全一致
交错抽取	按各段词数比例交错出题，前 60 题就跨 5 个以上频段，避免连着考一串冷门词
效果	同样 100 题：分层抽样区间 ±62 词，简单随机 ±91 词（约窄三成）

5.3 目标精度自适应停测

用户设目标半宽 `h`（±400 / ±250 / ±150），每次作答后重算当前区间半宽；半宽 ≤ h 且题量 ≥ 20 时提示可以收工。 题量是结果、不是设定——这是与"固定 20 题出结果"产品的本质区别。

5.4 区间估计的三层修正

```
se   = sqrt( max(p(1-p), 1e-6) / n ) * sqrt( (N-n) / (N-1) )    // Agresti-Coull 平滑 + 有限总体修正
half = 1.96 * se * N                                             // 折算回"词"的量纲
p'   = (k - f/k_opt) / (n - f/k_opt)                             // 四选一时先扣蒙对
vocab = p' * N,  CI = [ (p'-z·se)·N , (p'+z·se)·N ]
```

Agresti-Coull	抽到全对或全错时区间不会塌成 0 宽的点
有限总体修正	不放回抽样，乘 (N−n)/(N−1)；题量越接近整库，区间越窄，最后平滑过渡到普查
方差下限	`max(p(1-p), 1e-6)`，杜绝"误差为零"的假精度

5.5 四选一的蒙对校正

四选一有 25% 蒙对概率，直接用正确率估计掌握率会系统性偏高。校正公式 `(p − 1/k) / (1 − 1/k)`， 并把"该样本是否为四选一模式"记进样本，两类模式分别估计、不混算。

5.6 频段剖面与"缺口 × 权重"排序

频段	1k	1k-2k	2k-3k	3k-5k	5k-10k	10k-20k	20k+
词数（7,175 池）	738	610	478	874	1,556	1,598	1,321
权重	1	0.33	0.20	0.125	0.067	0.033	0.02

优先级 = 缺口词数 × 词频权重。实测：3k-5k 段缺 737 词排在 10k-20k 段缺 897 词之前，因为权重差 4 倍。 这条性质写成了可判定断言，防止以后改动把冷门词排到前面。

5.7 等级评估与地基约束

等级	掌握率	四级词数门槛	六级词数门槛	典型状态
S 卓越	≥ 92%	≥ 4,177 词	≥ 5,259 词	大纲几乎全覆盖
A 优秀	85–92%	3,859–4,176	4,859–5,258	核心扎实，零散漏洞
B+ 良好	75–85%	3,405–3,858	4,287–4,858	高频拿下，中低频成片缺口
B 中等	65–75%	2,951–3,404	3,716–4,286	阅读能应付，写作卡词
C 偏弱	50–65%	2,270–2,950	2,858–3,715	高频仍有明显漏洞
D 基础薄弱	< 50%	≤ 2,269	≤ 2,857	不到一半，直接刷题一直查词

地基约束：防止高频段空洞却评优

把最高频 1k 段整段丢掉，总掌握率仍可能有 85%，按比例照样评"优秀"——但这种结构读任何真实文本都会卡。 所以最高频段过低时对等级封顶：最高频 1k 段 < 60% → 封到 C；< 75% → 封到 B+；< 85% → 封到 A。 报告页会明确写出封顶原因，而不是偷偷降级。

5.8 多轮差分：区分"真学会"与"背了又忘"

新学会	上轮不认识 → 这轮认识
背了又忘	上轮认识 → 这轮不认识（复习第一优先级）
掉档	上轮模糊 → 这轮完全不认识
实现	每轮存 2 bit/词 的状态位图（约 1.8 KB） + 聚合快照；词表指纹不一致时只做聚合对比

5.9 词汇地图：182 格，图即入口

七段词频 × 26 首字母，颜色表示掌握率（绿 ≥80% / 黄 50–80% / 红 <50%），浓淡表示这一格测过多少。 点格子直接把这些缺口词组成一轮复测；Shift + 点则带着这一格的真实数字去问 AI。

5.10 回访卡：隔几天再打开，首页接上上次的结论

触发	至少有 1 次随机抽样/整库实测，且距上次检测满 3 天；有未完成的检测时让位给「继续检测」
三行结论	① 最该先补哪一段（target 与 weak 分开：高频三段还有洞就优先它们，冷门段最弱时如实说明不先补它）② 按每日时间折算补完天数 ③ 与上一轮相比是否超出 ±抽样误差
关闭	「×」收起本次（不落盘）/「以后不再提醒」永久关闭（设置可重开）
成本	全部本地计算，不联网、不消耗 AI 额度

5.11 自定义词书

支持 txt / csv / 粘贴导入，一行一个词，可选「词,释义」。导入前给出预览（总词数、命中内置词库、新增词条、 有释义比例、频段分布），并复用同一套引擎检测。边界写在界面上：**自定义词书是有偏样本，只报"对这本书的掌握率"， 不能换算成词汇量。**

5.12 每日可投入时间：一栏设置，四处文案

换算	`每天词数 = round(分钟 ÷ 1.5)`，夹在 5–200；代码里只有一处 `A.perDayWords()`
四处消费	报告页顶部「还差 X 词（约 N 天 · 每天 M 词）」、报告页分段补词建议、AI 计划、回访卡「补完约 N 天」
踩过的坑	其中两处曾把「每天 50 词」写死，设置改了不生效；现在统一走一个函数，并有断言锁死（改 60 分钟后四处必须同时变成 40 词/天）

5.13 界面、动效与无障碍

入场页	细线展台框绘制 → 标题逐字升起 → 数字滚动 → 鲸鱼绕场 → 光束扎入按钮 → 整屏对焦退场。内容早已渲染完成，退场无加载空窗
2.5D 桌宠	透视倾斜（转轴压脚底） + 接地投影 + 受光膜；可拖动、有重力、悬空挣扎（二阶系统由指针速度驱动）
暗色与主题	整套设计令牌双主题；主题切换的过渡曾把底色锁住，已修复并加断言
无障碍	入场页/模态期间给底层加 `inert`、完整焦点管理、`prefers-reduced-motion` 支持；对比度实测辅助文字 4.83:1、开关轨道 5.72:1
移动端	390 px 实测无横向溢出、主按钮在屏内、顶栏保持单行
发音	Web Speech API 朗读单词，**口音可切换（en-GB / en-US，默认英式）**；四六级听力本身是英音与美音混合，词库音标采用教材通用的英式标注，界面上直接说明这层关系并建议两种都听

5.14 界面实拍

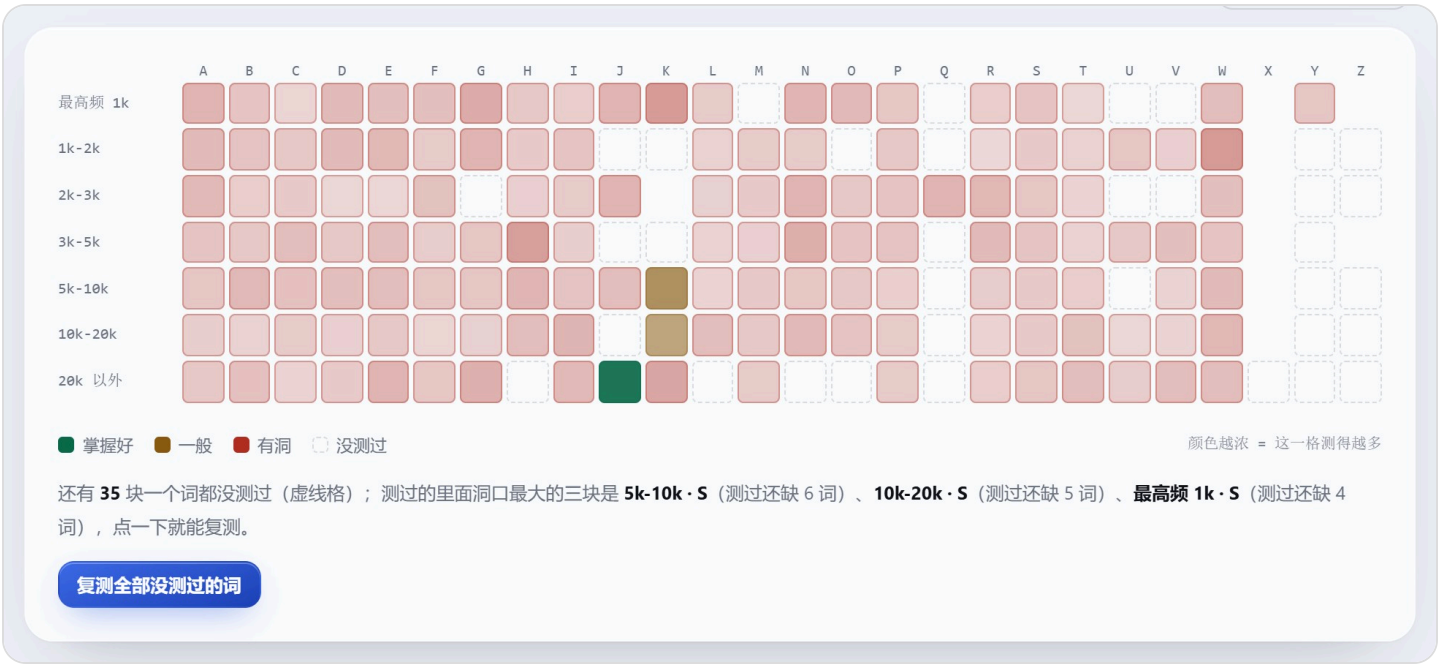
以下截图取自当前交付产物（桌面 1440×900，浏览器实拍）。



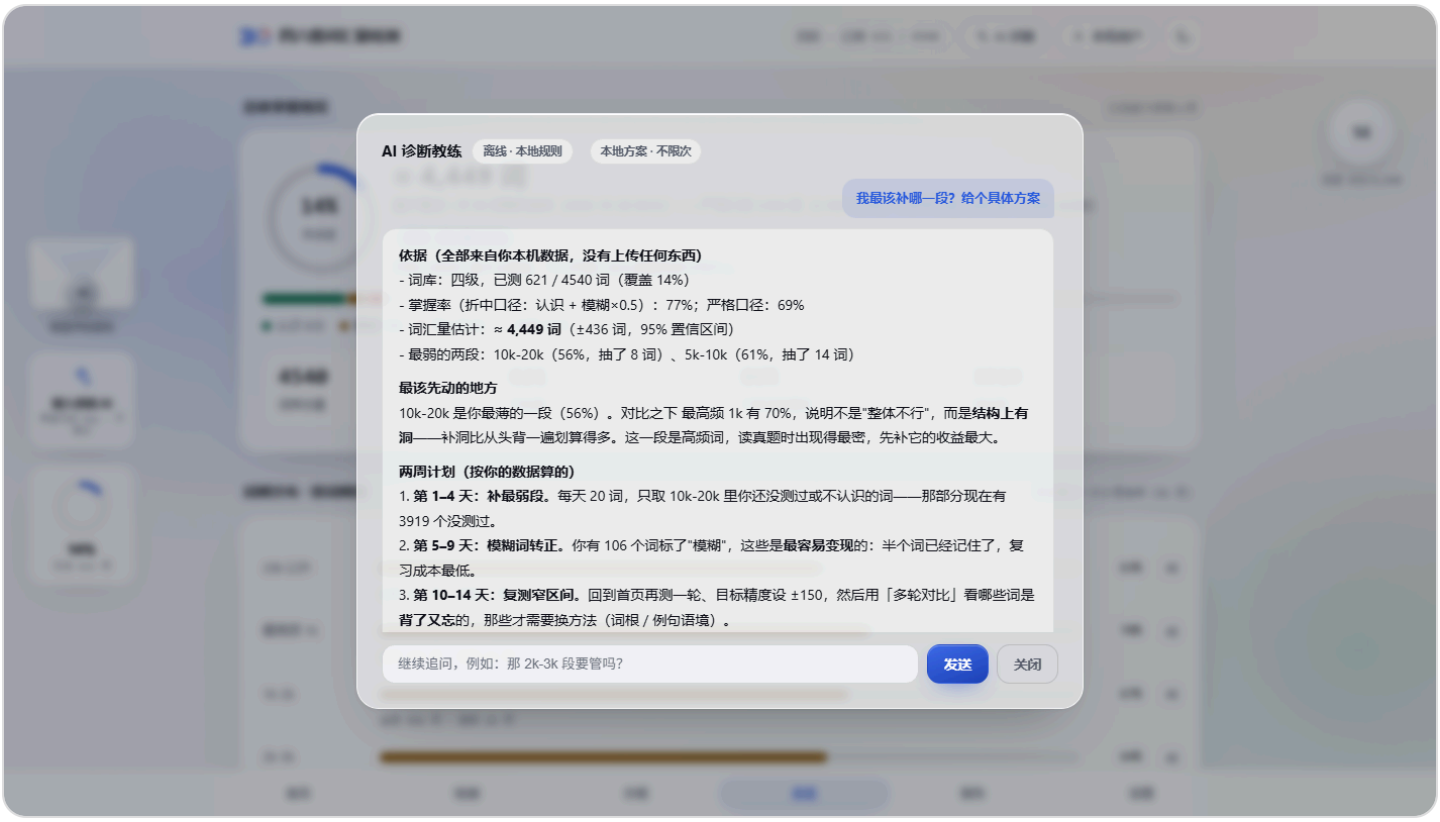
首页：词汇量 + 95% 区间 + 两套口径 + 四态统计 + 三种检测入口；下方是回访卡与分组进度。



报告页的补词清单：每段"还差多少词 · 掌握率 · 每天 N 词约需几天"，每条都能直接开始复测。



词汇地图：七段词频 × 26 首字母 = 182 格，颜色是掌握率、浓淡是测过多少，点格即复测。



AI 诊断面板：回答上方标出这次调了哪些工具，下方可展开"本次发送给模型的数据"。

6 测试与部署

6.1 测试体系（12 个套件 / 433 条离线断言）

套件	条数	覆盖什么
smoke-test.js（jsdom）	201	抽样、区间估计、等级、多轮、地图、档案、导出、回访卡、演示档案
scripts/run-btest.mjs（真实 Chrome）	55	布局不溢出、暗色切换、对比度、键盘焦点、地图与 AI 入口；自动读结果，有 FAIL 即非 0 退出
scripts/pet-test.mjs	40	拖动/重力/悬空物理/气泡版式/活动范围/自愈
scripts/check-intro.mjs	43	入场页分层浮现、退场干净、旁路、减少动效、手机布局
scripts/check-offline.mjs	7	孤立单文件（旁边无 assets）也能完整使用
scripts/check-recipient.mjs	20	空目录 + 全新浏览器配置 + 断网 + 双视口
scripts/check-ai-tiers.mjs	23	三档通路、额度授予/扣减/下限保护
scripts/check-ai-link.mjs	15	图表→AI 上下文、动作白名单、点击真的执行
scripts/check-book.mjs	17	词书解析/预览/切换/持久化/删除回退
scripts/check-ai-lock.mjs	6	无锁形态（可选授权功能的回归）
scripts/check-ai-offline.mjs	6	CDP 模拟断网：AI 面板给出本地方案，不空白、不报错、有可点动作
scripts/check-online-ai.mjs	7	联网主路径（需后端）：工具调用与动作

另有小程序侧三套一致性测试：引擎 1,302 条字段级、答题流程 34,310 条、页面冒烟 26 项，全部与网页版逐字段相等。

6.2 缺陷复盘：五个真出过的 bug

现象	根因与修法
入场页例句数显示 10,276	把「词→[英,中]」的扁平数组当对象数了两遍（5,138×2）。改为构建期算好语料真实规模注入
报告页「每天 50 词」写死	设置页改了不生效。收敛到 `A.perDayWords()`，并加"四处同时变"的断言
浏览器断言页一条都没跑	文件里一处语法错误，而生成脚本只打印 ok。补了 `run-btest.mjs` 自动跑分器
手机顶栏被品牌名挤成一列竖字	7 字品牌名在 390 px 下换行，顶栏涨到 200 px。窄屏让图标让位、名称单行省略，并加高度断言
页面多出一行乱码 `>3" >`	favicon 的 data URI 被 `/<link[^>]*>/` 正则截断。改为整行替换 + URL 编码，并加兜底清理

测试经验

① 断言要针对"真的动过"的元素，否则会假绿；② 时序相关的东西用轮询等条件，不要固定 sleep； ③ 生成式测试页必须配一个自动读结果的 runner；④ 改名要连测试里的期望字符串一起扫。

6.3 验收场景

离线交付	空目录 + 全新浏览器配置 + 屏蔽全部 http/https：20 项断言全过（答题、进度、档案、手机布局、顶栏）
手机双视口	390×844 与 1440×900 两档；无横向溢出、主按钮在屏内、无遮挡
两版产物	仓库版无任何密钥（`check-no-key.mjs`）；评委版可演示在线 AI
多端一致	小程序与网页版引擎逐字段相等（1,302 + 34,310 条断言，0 差异）

6.4 部署方式

形态	步骤	适用
离线单文件	双击 `index.html`，无需安装、无需联网	学生个人 / 断网环境
本地后端（可选）	`npm install` → 配 `.env` → `npm run server` → 浏览器打开 `http://127.0.0.1:8787`	演示带工具调用的 Agent
微信小程序	开发者工具「导入项目」→ 选 `miniprogram/` 目录 → 填 AppID → 编译；预览不需要备案	移动端 / 扫码体验

6.5 环境配置与依赖清单

```
# .env（可选，只在需要在线 AI 时使用；不要提交）
LLM_PROVIDER=deepseek          # deepseek | qwen | zhipu | ollama | mock
DEEPSEEK_API_KEY=sk-xxxxxxxx   # 对应厂商的 Key
DEEPSEEK_MODEL=deepseek-chat
# QWEN_API_KEY= / QWEN_MODEL=  ZHIPU_API_KEY= / ZHIPU_MODEL=
# OLLAMA_BASE=http://127.0.0.1:11434  OLLAMA_MODEL=qwen2.5:7b
PORT=8787
```

运行时	Node.js ≥ 18（仅后端需要）；浏览器 = 产物运行时，无依赖
生产依赖	**0 个**（`dependencies: {}`）
开发依赖	jsdom（页面测试）、pptxgenjs（生成演示稿）、opentype.js + pngjs + potrace（标识素材处理）
数据准备	`npm run data` 按固定 SHA 拉取词表；`node miniprogram/tools/gen-mini-data.mjs` 生成小程序数据
构建	`node build.js` / `node build.js --with-key`；产物不写时间戳，可复现

6.6 发布检查清单

① 构建	两种产物都构建一遍；`check-no-key.mjs` 通过
② 测试	smoke / 浏览器 / 桌宠 / 入场 / 离线 / 收件人 六套全绿
③ 派生物	截图重拍、PPT 重出、PDF 重导、桌面副本按 SHA256 比对
④ 文档	数字口径统一（断言数、体积、词条数）——历史上三次事故都出在"派生物没同步"

7 创新点说明

按评审要求分两部分列：**技术创新点**（工程上怎么做到的）与**应用创新点**（对用户意味着什么）。 每一条都能在产物里点到、在测试里查到。

7.1 技术创新点

创新点	做法	效果 / 证据
T1 词频分层抽样 + 目标精度自适应停测	七段等比例抽样，边测边算区间宽度，达标即停；题量是结果不是设定	同样 100 题，区间 ±62 vs 简单随机 ±91；用户可选 ±400/±250/±150
T2 区间估计的三层修正	Agresti-Coull 平滑 + 有限总体修正 (N−n)/(N−1) + 蒙对校正，另设方差下限 1e-6	抽到全对/全错时区间不塌陷成 0 宽，不给"误差为零"的假精度
T3 「缺口 × 词频权重」排序	优先级 = 缺口词数 × 段权重（1 → 0.02），而非按缺口绝对值	3k-5k 缺 737 词排在 10k-20k 缺 897 词之前；写成可判定断言
T4 地基约束（等级封顶）	最高频 1k 段 <60%/75%/85% 时把等级封到 C/B+/A	避免"高频段空一片但总分高"被评为优秀，并在报告里写明原因
T5 逐词 2 bit 位图 + 词表指纹的多轮差分	每轮存 2 bit/词 位图（约 1.8 KB）与 FNV-1a 指纹；指纹不符只做聚合对比	区分真学会 / 背了又忘 / 掉档；防止"拿两套词库硬比"
T6 确定性乱序（FNV-1a 定序）	用词自身哈希定序并交错抽取	任何前缀都是合法的分层样本；任何设备抽到同一批词，结果可复现
T7 离线可用的确定性诊断 + 三档降级	自带 Key → 作者额度 → 本地规则；数字始终由本机算	没有后端、没有额度、没有网络也能给出同等数字的结论
T8 单文件零依赖交付与可复现构建	构建期内联全部资源，产物不写时间戳；提交前扫密钥	同样源码构建出同样文件（可 SHA256 比对）；仓库无明文 Key

7.2 应用创新点

创新点	用户看到的样子	解决什么
A1 把误差当成一等公民	结果永远是"数字 + 95% 区间 + 两套口径"，误差写在大数字旁边	同类产品只给一个数，用户无法判断该不该信
A2 结论可执行到词与天	补词清单：先补哪一段、差多少词、每天几个、几天补完，且能一键开测	"知道差"和"知道下一步"之间的鸿沟
A3 回访闭环（回访卡）	隔几天再打开，首页三行话：补哪段、几天、涨跌是否超出误差	测完就结束的产品留不住人；又不滑向打卡催命
A4 AI 与图表双向联动	点频段条/地图格子就能带着真实数字提问；AI 的建议变成可点按钮	"分析在左、图在右"两套皮，用户要自己搬数据
A5 使用者档案隔离	同一台电脑多人使用互不可见，可切换/改名/删除	校园机房、宿舍共用电脑的真实场景
A6 演示档案（六个等级）	一键生成 S/A/B+/B/C/D 六个账号，各有不同的真实作答	等级要背几千词才能升，现场无法演示；但不是贴假等级
A7 把边界写进界面	自定义词书只报"对这本书的掌握率"，常驻提示不外推词汇量	工具最容易靠"看起来专业"越界给结论
A8 一套引擎多端复用	网页 + 微信小程序，5 个页面，主包 1.56 MB	移动端也能测；两端数字必须一致（1,302 + 34,310 条一致性断言）

8 总结与展望

8.1 已完成

一个 2.11 MB 的单文件 Web 应用：五入口检测、带区间的词汇量估计、七段诊断、等级与地基约束、多轮差分、 182 格词汇地图、回访卡、自定义词书、使用者档案、三档 AI 通路、离线可用的本地规则引擎， 外加一个同源引擎的微信小程序版本。全部由单人完成，427 条离线断言守着回归。

8.2 可改进的方向

方向	为什么值得做	难点
错因归类	现在只知道"不会"，不知道是形近、义近还是搭配不会；加上错因能进一步细化补词策略	需要更多交互设计
发音与听写	小程序端缺 TTS；接入后可覆盖听说维度	插件或后端依赖
在线演示环境	让评委不下载就能点开	需要托管与合规
小程序 AI 诊断	移动端也能追问	需配置 request 合法域名或云函数转发

8.3 长期展望

这个项目真正想验证的事情是：**把"误差"当成产品的一等公民**，用户会不会更信任、更愿意按结论行动。 如果这套"测量 + 处方"的框架成立，它可以迁移到其他可量化的学习能力上（听力词汇、语法覆盖、阅读速度）， 核心始终是同一件事：先把数测准，再说下一步。

附录

附录 A　关键参数速查

词库规模	四级 4,540 词 / 六级 5,716 词 / 含派生 7,175 词（派生 1,459）
例句	9,204 句英中对照，覆盖 5,138 个词（每词内联 1 句）
区间	z = 1.96；方差下限 1e-6；有限总体修正 (N−n)/(N−1)
等级阈值	0.92 / 0.85 / 0.75 / 0.65 / 0.50；封顶线 0.60 / 0.75 / 0.85（按最高频 1k 段）
频段权重	1 / 0.33 / 0.20 / 0.125 / 0.067 / 0.033 / 0.02
每日时间	分钟 ÷ 1.5，夹在 5–200；设置范围 5–180
AI	工具 8+1；最多 3 轮；输出 1000 token；历史 6 条；问题截断 120 字；target ∈ {150,250,400}
存储	2 bit/词 ≈ 1.8 KB 每轮；最多 12 轮；FNV-1a 指纹

附录 B　术语表

口径（严格/折中）	严格只算「认识」；折中把「模糊」按 0.5 计入。两套都展示
缺口 / 未测	缺口 = 测过还不会（真正的洞）；未测 = 压根不知道（不构成结论）
地基约束	最高频段过低时对等级封顶，防止"高频空一片却因总分高而评优"
回访卡	隔几天再打开时首页出现的三段结论卡片，不弹窗、可永久关闭
词表指纹	词表内容的 FNV-1a 摘要，用于判断两轮是否可比

附录 C　数据来源与许可

词库	公开四六级大纲词表整理，附国际音标与词频分层；界面与算法为本项目原创（MIT）
例句	Tatoeba 英中对照语料，**CC-BY 2.0 FR**；每条例句标注来源
桌宠立绘	DS鲸鱼娘 · Sutera-Diffusus · MIT（经 1TRYOUT/dsh-whale-pixel-pet 分发，保留署名）
生成式素材	标识「30」由作者提供原图，矢量化后内联；无第三方受限字体嵌入（见 LICENSING.md）

附录 D　答辩常见追问

可能的问题	一句话应答
你们这是背单词 App 吗?	不是。我们只做测量与诊断：测准 + 开补词清单，背单词交给你习惯的工具。
测出来的数凭什么可信?	误差写在数字旁边：分层抽样 + 有限总体修正 + 蒙对校正 + 双口径，抽样与估计有 201 条断言守着。
AI 具体做了什么?	只做解释与规划：所有数字来自 8 个工具的返回值，模型不许自己算数；数据不足时它会拒绝下结论。
是向量 RAG 吗?	不是。本地语料倒排索引 + 工具按需检索的轻量 RAG；向量方案会拖几十 MB 权重，毁掉单文件与断网可用。
断网能用吗?	能。单文件双击即开，答题、进度、报告、本地方案全部离线可用。
为什么还要做小程序?	同一套引擎换一种交付形态：小程序主包 1.56 MB，与网页版逐字段一致（1,302 + 34,310 条一致性断言）。
商业化怎么想?	不卖课、不导流、不弹广告；AI 用你自己的 Key 或完成检测换来的额度，成本可见。

本文档描述的是当前交付版本（单文件 2.11 MB / 433 条离线断言 / 词库 7,175 词 / 例句 9,204 句）。 实现细节、逐条设计决策与踩过的坑另见仓库内 `NEXT.md`、`README.md` 与报告系列。